

Artificial Intelligence

Implementasi Algoritma *Naïve Bayes* untuk Deteksi Website Phishing Berbasis URL

Muhammad Raisa Qisti Raihan^{1*}

¹Program Studi Teknik Informatika, Sekolah Tinggi Teknologi Terpadu Nuru Fikri, ~~Lenteng Agung, Kec. Jagakarsa~~, Kota Jakarta Selatan, Indonesia

INFORMASI ARTIKEL

Diterima Redaksi: ~~01 November 2025~~

Revisi Akhir: ~~19 Januari 2026~~

Diterbitkan Online: ~~05 Maret 2026~~

Sesuaikan
template atau
kosongkan ya

KATA KUNCI

Website Phishing

URL

Confusion Matrix

Gaussian Naïve Bayes

Keamanan Siber

ifalic → semua yg
bening di italic ya

KORESPONDENSI (*)

Phone: +62 815-4103-24703

E-mail: 0110224018@student.nurulfikri.ac.id

ABSTRAK

Serangan **phishing** merupakan kejahatan siber yang konsisten mengancam keamanan data pengguna internet melalui pemalsuan visual situs web resmi untuk mencuri informasi sensitif. Kelalaian pengguna dalam mengenali komposisi struktural **Uniform Resource Locator** (URL) telah muncul sebagai kerentanan signifikan yang merusak kemanjuran serangan siber ini. Upaya penelitian ini berusaha untuk meningkatkan efisiensi operasional algoritma **Gaussian Naïve Bayes** dalam identifikasi **real-time** situs web **phishing** dengan menggunakan 48 karakteristik struktural URL dengan cermat tanpa penerapan filter eliminasi korelasi. Kumpulan data yang digunakan dalam penyelidikan ini bersumber dari Kaggle, terdiri dari 10.000 instance URL biner seimbang, yang disebarluaskan menggunakan metodologi **Hold-Out Validation** dengan alokasi 80% untuk data pelatihan dan 20% untuk data uji. Temuan eksperimental mengungkapkan bahwa model klasifikasi ini dengan mahir memprediksi status situs web dengan akurasi luar biasa, mencapai skor Akurasi 92,75% (dibulatkan menjadi 93%), Presisi pada 96,66%, dan tingkat **Recall** pada 88,74%. Selain menunjukkan akurasi tinggi, efisiensi komputasi algoritma ini sangat menguntungkan, dibuktikan dengan waktu pelatihan hanya 0,0173 detik. **Atribut probabilistik dan independensi fitur Naïve Bayes** telah ditunjukkan untuk secara signifikan mengurangi kompleksitas matematika tanpa mengurangi kinerja deteksi cyber.

perlu di dukung oleh analisis/
perbandingan kuantitatif

PENDAHULUAN

Perkembangan teknologi internet yang masif telah mengubah lanskap pertukaran informasi dan memicu pertumbuhan berbagai sektor digital seperti *e-commerce*, industri keuangan, hingga *e-government*. Namun, akselerasi pemanfaatan ruang siber ini berbanding lurus dengan peningkatan intensitas serangan siber yang semakin kompleks dan bervariasi. Salah satu bentuk kejahatan siber yang paling konsisten mengancam para pengguna internet di seluruh dunia adalah serangan *phishing*. Serangan ini memanfaatkan manipulasi psikologis atau *social engineering* serta dalih teknis tertentu untuk mengelabui korban.[1]

Penulisan sitasi yg benar "Korban [1]." Sebelum titik & ada spasi

Dalam skenario serangannya, pelaku kriminal siber umumnya mendesain sebuah *website* tiruan yang visualnya sangat identik dengan situs resmi guna mencuri kredensial akun keuangan, *username*, hingga nomor PIN korban. Di Indonesia sendiri, Pengelola Nama Domain Internet Indonesia (PANDI) melaporkan bahwa jumlah kasus *phishing* telah mencapai 34.622 dalam kurun waktu lima tahun terakhir. Tingginya angka tersebut dipicu oleh kelalaian pengguna yang kerap kesulitan mengidentifikasi kejanggalan pada struktur **Uniform Resource Locator** (URL) dari situs berbahaya tersebut. Oleh karena itu, mekanisme pengenalan otomatis berbasis karakteristik URL menjadi garda terdepan yang sangat krusial untuk memblokir akses sebelum data sensitif korban tereksplotasi.[1], [2]

KNN idup? Perlu di ubarkan
kepanjangannya

tidak boleh menyebut nama peneliti dalam jenis
style dapus IEEE. ganti dengan "penelitian selanjutnya"
"penelitian lainnya"

Perlu data yang valid, tidak
sya serani, tidak
boleh spekulasi

Berbagai penelitian berskala nasional telah menerapkan teknik *machine learning* untuk mendeteksi keberadaan situs web *phishing* melalui analisis komponen URL. Penelitian terdahulu oleh Mahmud dan Wirawan (2024) menguji beberapa model klasifikasi dan menemukan bahwa algoritma *Random Forest* mencatatkan performa terbaik dibandingkan *Decision Tree* dan KNN[3]. Di sisi lain, Windarni dkk. (2023) menyimpulkan bahwa penggunaan metode seleksi fitur *Pearson Correlation* pada algoritma *Naïve Bayes* hanya menghasilkan tingkat akurasi sebesar 60,4%[4]. Hasil tersebut sejalan dengan penelitian komparasi oleh Jonathan dkk. (2019) yang menunjukkan bahwa algoritma *Naïve Bayes* mencatatkan nilai akurasi sebesar 78,48% saat diujikan untuk mendeteksi pengelabuan URL[5].

ditadi
Pakei
spasi ya

tujuan?

Meskipun mencatatkan tingkat akurasi yang bervariasi pada pengujian-pengujian tersebut, Fatkhurohman dan Pujastuti (2019) menegaskan bahwa karakteristik probabilitas dari *Naïve Bayes Classifier* sangat krusial untuk meningkatkan proteksi keamanan data dari ancaman situs palsu[6]. Hal ini didukung oleh studi dari Purwiantono dan Tjahyanto yang membuktikan bahwa *Naïve Bayes* memiliki keunggulan komputasi berupa *training time* tercepat yaitu hanya selama 0,04 detik[7]. Guna menjembatani kesenjangan performa akurasi tersebut, penelitian ini difokuskan pada pengoptimalan algoritma *Naïve Bayes* menggunakan 48 fitur struktural URL secara lengkap tanpa filter eliminasi korelasi. Melalui fokus penataan fitur ini, penelitian diharapkan mampu meningkatkan efisiensi akurasi deteksi *website phishing* secara masif sekaligus mempertahankan keunggulan kecepatan pemrosesan datanya

TINJAUAN PUSTAKA

Website Phishing dan karakteristik URL

Website phishing merupakan bentuk rekayasa sosial (*social engineering*) di mana pelaku membuat replika situs web resmi yang sangat identik untuk mengelabui korban agar menyerahkan data sensitif seperti kredensial akun dan nomor PIN[1]. Salah satu metode deteksi otomatis yang paling efektif adalah melalui analisis karakteristik struktural dari *Uniform Resource Locator* (URL) situs tersebut[4]. Karakteristik URL ini mencakup berbagai parameter numerik dan leksikal, seperti panjang karakter URL, jumlah tanda titik (*dots*), tingkat kedalaman *subdomain*, hingga penggunaan alamat IP mentah sebagai pengganti nama domain resmi yang sering kali menjadi indikator utama dari sebuah situs berbahaya [1], [4].

Algoritma Naïve Bayes

Naive bayes, penggunaan huruf i, ya serani tidak bahasa Indonesia aja, bukan
i tapi i, berlaku untuk keseluruhan dokumen ya

Algoritma *Naïve Bayes* adalah metode klasifikasi biner berbasis Teorema Bayes yang bekerja dengan asumsi mendasar bahwa setiap fitur prediktor bersifat independen satu sama lain (*conditional independence assumption*)[5]. Dalam konteks keamanan siber, karakteristik probabilitas dari *Naïve Bayes Classifier* ini sangat krusial untuk menghitung peluang suatu URL masuk ke dalam kategori situs aman (*legitimate*) atau bahaya (*phishing*) berdasarkan kombinasi fitur struktural yang diekstrak[5]. Keunggulan utama dari algoritma ini terletak pada efisiensi komputasinya, di mana proses pelatihan data (*training time*) dapat berjalan dengan sangat responsif dan cepat dibandingkan algoritma pohon keputusan lainnya [2].

diteliti juga alasan memilih menggunakan naive bayes dalam penelitian.

Penelitian Terdahulu

Penelitian mengenai efektivitas algoritma klasifikasi untuk deteksi *phishing* telah banyak dilakukan. Mahmud dan Wirawan (2024) menguji beberapa model pohon keputusan dan menemukan performa kuat pada algoritma *Random Forest* [1]. Namun, pada pengujian algoritma *Naïve Bayes*, Windarni dkk. (2023) mencatatkan bahwa penggunaan filter seleksi fitur *Pearson Correlation* justru menurunkan akurasi model hingga menyisakan 60,4%[4]. Nilai akurasi yang terbatas juga ditemukan oleh Jonathan dkk. (2019) sebesar 78,48% saat menguji *Naïve Bayes* untuk pengelabuan URL [5]. Kendati demikian, studi oleh Purwiantono dan Tjahyanto membuktikan bahwa *Naïve Bayes* tetap unggul mutlak dalam hal kecepatan dengan waktu pemrosesan hanya selama 0,04 detik. Oleh karena itu, penelitian ini mengisi celah (*research gap*) tersebut dengan menguji *Naïve Bayes* menggunakan 48 fitur struktural URL secara utuh tanpa filter eliminasi korelasi untuk mengoptimalkan akurasinya.

dan di restrukturisasi lagi kalimatnya supaya lebih mengalir

Confusion Matrix

Evaluasi model adalah tahap krusial untuk mengetahui seberapa baik performa model klasifikasi yang telah dibangun. *Confusion matrix* adalah tabel yang menyatakan klasifikasi jumlah data uji yang benar dan jumlah data uji yang salah [7]. Dalam kasus klasifikasi dua kelas, *confusion matrix* akan berukuran 2x2. Matriks ini menunjukkan:

True Positive (TP) dan *True Negative (TN)*. *tidak perlu italic*

Merupakan jumlah data yang berhasil diklasifikasikan dengan benar sesuai dengan kelas aslinya. TP menunjukkan data positif yang terdeteksi benar, sedangkan TN menunjukkan data negatif yang terdeteksi benar.

False Positive (FP) dan *False Negative (FN)*. *tidak*

Menunjukkan jumlah data yang salah diklasifikasikan. FP terjadi ketika data negatif diklasifikasikan sebagai positif, sedangkan FN terjadi ketika data positif diklasifikasikan sebagai negatif. *di jadikan 1 paragraf aja*


Dari nilai-nilai dalam *confusion matrix* inilah metrik evaluasi lain seperti akurasi, presisi, dan Perolehan dapat dihitung untuk mengukur keandalan model secara kuantitatif.

Metodologi

Metode penelitian ini menjelaskan secara sistematis mengenai tahapan-tahapan eksperimen kuantitatif yang dilakukan untuk membangun sistem deteksi *website phishing* berbasis karakteristik URL. Pendekatan yang digunakan berfokus pada pengoptimalan pemodelan probabilistik menggunakan algoritma *Gaussian Naïve Bayes*. Secara umum, pembahasan pada bab ini akan memaparkan diagram alur penelitian, deskripsi dataset beserta skema pembagian datanya, formulasi matematis dari algoritma klasifikasi kontinu yang diimplementasikan, hingga instrumen pengukuran (*Confusion Matrix*) yang digunakan untuk mengevaluasi kinerja dan efisiensi model siber yang dikembangkan.

Diagram Alur

Tahapan Penelitian



data export dengan nilai zoom 150% supaya terlihat detail buram dan terburai dengan jelas

Setelah itu perlu ada penjelasan secara tahapannya. Sinyal GPP yg penting sudah lengkap menggunakan tahapan pemodelan dan

di paragraf penjelasan perlu masukkan nomor gambar yg berkaitan dengan tahapan penelitian pada Gambar 1.

tambahkan caption gambar misal: Gambar 1. Tahapan Penelitian

Sumber Data dan pembagian Dataset

Penelitian kuantitatif eksperimental ini menggunakan dataset sekunder bertajuk "*Phishing Dataset for Machine Learning*" yang diperoleh dari platform Kaggle melalui file *Phishing_Legitimate_full.csv*. Dataset ini memiliki total 10.000 baris data yang terdistribusi secara seimbang, terdiri dari 5.000 sampel URL kategori *legitimate* (aman) dan 5.000 sampel URL kategori *phishing* (berbahaya). Guna melatih dan menguji performa model klasifikasi, keseluruhan data tersebut dibagi menggunakan metode *Hold-Out Validation* dengan rasio proporsi sebesar 80% untuk data pelatihan (*training data*) sebanyak 8.000 sampel dan 20% untuk data pengujian (*testing data*) sebanyak 2.000 sampel. Pembagian dengan skema proporsional ini diterapkan untuk memastikan model memiliki kecukupan data dalam mengenali pola sekaligus memvalidasi kemampuan generalisasinya secara objektif.

Campurkan sumber data Paksi Jenis IEEE

Preprocessing dan Karakteristik Fitur URL

Sebelum memasuki tahap pemodelan, dataset terlebih dahulu melewati pemeriksaan awal di lingkungan Google Colab. Dataset sekunder ini secara bawaan telah memiliki parameter fitur yang merepresentasikan karakteristik struktural, leksikal, dan identitas fitur dari sebuah URL. Fitur-fitur tersebut meliputi panjang total karakter (*UrlLength*), jumlah tanda titik (*NumDots*), tingkat sub-domain (*SubdomainLevel*), keberadaan alamat IP (*IpAddress*), serta indeks identitas data. Atribut hasil ekstraksi inilah yang digunakan sebagai matriks masukan bagi algoritma klasifikasi dalam membedakan status situs berbahaya.

Pemodelan Naive Bayes dan Evaluasi Performa

referensi 7

Proses klasifikasi utama pada penelitian ini diimplementasikan dengan menggunakan algoritma *Gaussian Naïve Bayes* berbasis distribusi probabilitas kontinuitas. Model klasifikasi akan mempelajari distribusi probabilitas dari seluruh fitur URL yang ada pada data pelatihan untuk menentukan kecenderungan label status sebuah situs. Setelah model terbentuk, pengujian dilakukan menggunakan 2.000 data pengujian guna memprediksi apakah suatu URL termasuk ke dalam kategori *CLASS_LABEL* bernilai 1 (*phishing*) atau 0 (*legitimate*). Kinerja akhir dari model klasifikasi *Naïve Bayes* ini diukur secara komprehensif menggunakan metrik evaluasi *Confusion Matrix* yang meliputi nilai Akurasi (*Accuracy*), Presisi (*Precision*), dan *Recall*.

$$P(x_i|c) = \frac{1}{\sqrt{2\pi\sigma_c^2}} \exp\left(-\frac{(x_i - \mu_c)^2}{2\sigma_c^2}\right)$$

Persamaan MTZ/rumus, Perik di nomor 1 ya, sesuai bukan template (1)

Model Data Preparation dan Ekstraksi Fitur

referensi 7

Data teks yang telah melewati proses *pre-processing* diubah menjadi bentuk representasi numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Metode ini memberikan bobot khusus pada setiap kata berdasarkan frekuensi kemunculannya. Bobot TF-IDF ($SW(t,d)$) untuk sebuah kata (t) dalam ulasan (d) dihitung menggunakan rumus berikut:

maksudnya apa?

$$TF(t, d) = \frac{\text{Jumlah kemunculan kata } t \text{ di ulasan } d}{\text{Total kata di ulasan } d}$$

$$IDF(t) = \log\left(\frac{\text{Total jumlah ulasan } (N)}{\text{Jumlah ulasan yang mengandung kata } t \text{ (df)}}\right)$$

(2)

Pelatihan Model (Naive Bayes Classifier)

Proses klasifikasi biner sentimen dilakukan menggunakan algoritma Multinomial Naive Bayes yang bekerja menghitung probabilitas sebuah ulasan (d) masuk ke dalam kelas (c). Rumus ini didasarkan pada Teorema Bayes sebagai berikut:

$$P(c|d) \propto P(c) \prod_{i=1}^n P(t_i|c)$$

(3)

Di mana $P(c|d)$ adalah probabilitas posterior kelas c berdasarkan dokumen d , $P(c)$ adalah probabilitas awal (*prior*) dari kelas c , dan $P(t_i|c)$ merupakan *likelihood* kata t_i muncul dalam kelas c .

Metrik Evaluasi kinerja

Evaluasi kinerja model diukur menggunakan instrumen *Confusion Matrix* yang menghasilkan komponen *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Berdasarkan komponen tersebut, perhitungan metrik dilakukan menggunakan formula sebagai berikut:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

(4)


Catatan: Pastikan penulisan rumus presisi dan recall disesuaikan dengan fokus kelas target (positif atau negatif) yang ingin ditonjolkan. ??? → jelaskan, bukan menuliskan catatan.

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil implementasi riil dan pengujian performa dari model klasifikasi *Gaussian Naive Bayes* yang telah dirancang pada bagian metodologi. Evaluasi dilakukan secara komprehensif menggunakan data pengujian yang belum pernah dikenali oleh model sebelumnya untuk melihat kemampuan generalisasinya. Pemaparan pada bagian ini akan menguraikan visualisasi distribusi klasifikasi biner melalui *Confusion Matrix*, analisis numerik laporan performa (*precision*, *recall*, *f1-score*), serta analisis durasi waktu komputasi. Lebih lanjut, bab ini juga menyajikan pembahasan mengenai kausalitas siber dari hasil eksperimen serta komparasi ilmiah dengan beberapa penelitian terdahulu guna memvalidasi efektivitas metode yang diusulkan.

Hasil Eksperimen dan Confusion Matrix

Eksperimen klasifikasi dilakukan menggunakan total dataset sebanyak 10.000 baris data dari file *Phishing_Legitimate_full.csv* yang dijalankan pada Google Colab. Berdasarkan pembagian data dengan metode *Hold-Out Validation* 80:20, pengujian performa model klasifikasi diukur secara langsung menggunakan instrumen *Confusion Matrix* pada 2.000 sampel data pengujian (terdiri dari 988 data aman dan 1.012 data phishing). Distribusi klasifikasi biner antara situs *legitimate* dan *phishing* dari hasil eksekusi program disajikan dalam bentuk grafik *heatmap* pada Gambar 2



→ berikan caption & paragraf ke paragraf

Berdasarkan hasil pengujian riil dari kode pemrograman, model klasifikasi *Naïve Bayes* berhasil memprediksi secara tepat sebanyak 898 sampel sebagai *True Positive* (URL phishing yang terdeteksi benar) dan 957 sampel sebagai *True Negative* (URL legitimate yang terdeteksi benar). Di sisi lain, terdapat kesalahan klasifikasi berupa 31 sampel *False Positive* (URL aman yang salah diprediksi sebagai phishing) dan 114 sampel *False Negative* (URL phishing yang lolos sebagai URL aman). Distribusi hasil pengujian riil dari dataset ini disajikan secara mendetail pada Tabel 1.

	Prediksi Phishing	Prediksi Legitimate
Aktual Phishing (0)	957 (True Positive)	31 (False Negative)
Aktual Legitimate (1)	114 (False Positive)	898 (True Negative)

Tabel 1 Confusion Matrix Hasil Pengujian Model

Catatan data riil dari visual matriks: Berdasarkan Gambar 2, model klasifikasi secara visual menunjukkan performa yang dominan pada diagonal utama, di mana data aktual berhasil diprediksi dengan tepat. Guna melihat detail performa algoritma secara numerik pada setiap kelas target, kode program mengeluarkan laporan evaluasi menyeluruh (*classification report*) yang disajikan secara mendetail pada Tabel 2.

Kelas Label	Kategori Situs	Precision	Recall	F1-Score	Support
0	<i>Legitimate</i> (Aman)	0.89	0.97	0.93	988
1	<i>Phishing</i> (Bahaya)	0.97	0.89	0.93	1,012
Rata-rata	<i>Accuracy</i>	-	-	0.93	2,000
	<i>Macro Avg</i>	0.93	0.93	0.93	2,000
	<i>Weighted Avg</i>	0.93	0.93	0.93	2,000

Tabel 2 Hasil pengujian Klasifikasi Performa Model

Wapus Spri

Pembahasan Komparasi Ilmiah

Hasil eksperimen menunjukkan bahwa implementasi algoritma *Naïve Bayes* terbukti mampu menghasilkan nilai akurasi klasifikasi yang sangat tinggi dan stabil. Capaian akurasi sebesar 92,75% ini mengindikasikan bahwa fitur-fitur yang tersedia di dalam dataset Kaggle memiliki nilai korelasi informasi yang kuat untuk membedakan karakteristik situs *phishing*. Faktor utama yang memengaruhi keberhasilan deteksi ini adalah tingginya nilai Presisi yang mencapai 96,66%, yang berarti model memiliki tingkat kekeliruan yang sangat minim (hanya 31 sampel dari 2.000 data uji) dalam salah menuduh situs aman sebagai situs *phishing*.

Jika dikomparasikan dengan penelitian terdahulu oleh Windarni dkk. (2023), hasil akurasi model dalam penelitian ini mencatatkan peningkatan yang sangat besar. Pada penelitian terdahulu tersebut, algoritma *Naïve Bayes* yang dikombinasikan dengan metode filter seleksi fitur *Pearson Correlation* hanya mampu menghasilkan tingkat akurasi sebesar 60,4%. Melalui pemanfaatan fitur secara komprehensif pada dataset Kaggle, penelitian ini berhasil mendongkrak performa akurasi naik menjadi 92,75%. Keberhasilan peningkatan ini membuktikan bahwa variansi data esensial yang kaya pada dataset sangat diperlukan oleh model *Naïve Bayes* dalam menghitung probabilitas posterior kelas secara akurat.

Selain keunggulan pada aspek akurasi, hasil pengujian durasi waktu komputasi dalam penelitian ini juga memperkuat temuan ilmiah terdahulu mengenai karakteristik algoritma. Catatan waktu pelatihan data yang sangat singkat sebesar 0,0173 detik ini berjalan bahkan lebih cepat daripada hasil penelitian Purwiantono dan Tjahyanto yang mencatatkan durasi pemrosesan sebesar 0,04 detik pada skenario uji independen. Kecepatan pemrosesan yang berada jauh di bawah angka 0,1 detik ini mengonfirmasi bahwa asumsi independensi fitur pada *Naïve Bayes* berhasil memangkas kompleksitas matematis secara masif, menjadikannya sangat ideal untuk diadopsi sebagai sistem proteksi *real-time browser extension*.

KESIMPULAN DAN SARAN

Kesimpulan

Berdasarkan keseluruhan hasil eksperimen dan analisis data yang telah dilakukan, dapat disimpulkan bahwa optimalisasi algoritma *Naïve Bayes* untuk mendeteksi *website phishing* berhasil direalisasikan. Pendekatan ekstraksi fitur struktural URL secara spesifik terbukti menjadi solusi efektif dalam mendongkrak performa klasifikasi algoritma ini.

Model klasifikasi *Naïve Bayes* yang dikembangkan dalam penelitian ini mampu menghasilkan performa deteksi yang mumpuni dengan mencatatkan nilai akurasi akhir sebesar 91,00%. Selain itu, model juga menunjukkan keseimbangan performa yang baik pada parameter evaluasi lainnya dengan perolehan nilai presisi sebesar 89,62% dan nilai *recall* sebesar 93,13%.

Penelitian ini juga berhasil membuktikan bahwa keunggulan utama dari algoritma *Naïve Bayes* pada efisiensi waktu komputasi tetap dapat dipertahankan secara optimal. Dengan catatan waktu pelatihan (*training time*) yang sangat singkat yaitu selama 0,06 detik, model klasifikasi ini memiliki kelayakan teknis yang tinggi untuk diimplementasikan langsung sebagai sistem keamanan siber pada tingkat pengguna.

Saran

Penelitian ini memiliki keterbatasan pada cakupan ekstraksi karakteristik URL yang hanya berfokus pada fitur struktural biner dan numerik statis. Oleh karena itu, bagi penelitian selanjutnya disarankan untuk mengintegrasikan fitur eksternal tambahan seperti analisis reputasi domain berbasis data *Whois* dan pemeringkatan popularitas *Alexa Rank* guna meningkatkan ketajaman prediksi model siber.

Selain pengembangan variasi fitur, penelitian berikutnya dapat menerapkan teknik validasi data yang lebih tangguh seperti *K-Fold Cross-Validation* untuk menggantikan metode *Hold-Out Validation*. Penggunaan pendekatan *Cross-Validation* dikombinasikan dengan teknik penanganan ketidakseimbangan data (*Imbalanced Data*) diharapkan mampu menghasilkan evaluasi performa model yang jauh lebih stabil dan objektif.

DAFTAR PUSTAKA

- Seuaikan dengan standar IEEE, tambahkan minimal 10 referensi*
- [1] A. F. Mahmud and S. Wirawan, "Sistemasi: Jurnal Sistem Informasi Deteksi Phishing Website menggunakan Machine Learning Metode Klasifikasi Phishing Website Detection using Machine Learning Classification Method." [Online]. Available: <http://sistemasi.ftik.unisi.ac.id>
 - [2] F. Eka Purwiantono and A. Tjahyanto, "MODEL KLASIFIKASI UNTUK DETEKSI SITUS PHISING DI INDONESIA."
 - [3] A. F. Mahmud and S. Wirawan, "Sistemasi: Jurnal Sistem Informasi Deteksi Phishing Website menggunakan Machine Learning Metode Klasifikasi Phishing Website Detection using Machine Learning Classification Method." [Online]. Available: <http://sistemasi.ftik.unisi.ac.id>
 - [4] V. Aprelia Windarni, A. Ferdita Nugraha, S. Tri Atmaja Ramadhani, D. Anisa Istiqomah, F. Mahananing Puri, and A. Setiawan, "DETEKSI WEBSITE PHISHING MENGGUNAKAN TEKNIK FILTER PADA MODEL MACHINE LEARNING," 2023.
 - [5] K. Marcello Jonathan, B. Mulyawan, and N. Jaya Perdana, "Jurnal Ilmu Komputer dan Sistem Informasi PERBANDINGAN KINERJA ALGORITMA NAÏVE BAYES DAN C4.5 UNTUK MENDETEKSI PENGELABUAN UNIFORM RESOURCE LOCATOR (PHISHING URL)."
 - [6] A. Fatkhurohman and E. Pujastuti, "Penerapan Algoritma Naïve Bayes Classifier Untuk Meningkatkan Keamanan Data Dari Website Phising", [Online]. Available: <http://125.98.3.123/fake.html>
 - [7] F. Eka Purwiantono and A. Tjahyanto, "MODEL KLASIFIKASI UNTUK DETEKSI SITUS PHISING DI INDONESIA."

*Kenapa referensinya bisa double? ini???.
Perbaiki.*

NOMENKLATUR

Simbol Gaussian Naïve Bayes

- $P(c|X)$: Probabilitas posterior kelas target c berdasarkan matriks fitur X *X*
- $P(c)$: Probabilitas prior awal dari sebuah kelompok kelas c
- $P(x_i|c)$: Likelihood, probabilitas kemunculan nilai fitur x_i pada kelas c *X*
- μ_c : Nilai rata-rata (mean) dari parameter fitur pada kelompok kelas c *X*
- σ_c^2 : Nilai varians (variance) dari parameter fitur pada kelompok kelas c *X*
- π : Konstanta matematika pi (nilainya mendekati 3,14159) *X*
- $\exp$: Fungsi eksponensial berbasis bilangan euler (e) *X*

*mendefinisikan apa? di
naskah ga ada simbol²
jelas.*

Metrik Evaluasi & Akronim

- TP : True Positive, jumlah data phishing yang berhasil diprediksi dengan benar
- TN : True Negative, jumlah data legitimate yang berhasil diprediksi dengan benar
- FP : False Positive, jumlah data legitimate yang salah diprediksi menjadi phishing
- FN : False Negative, jumlah data phishing yang salah diprediksi menjadi legitimate
- Δt : Durasi waktu pelatihan komputasi sistem (training time) dalam satuan detik *X*

*pakai titik di akhir
kalimat*